



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر
گزارش فازهای سوم و چهارم پروژه
درس آزمایشگاه اینترنت اشیا

عنوان:

**نقد مقاله، بازتولید و توسعه:
دسته‌بندی بدافزار بر پایه‌ی قطعه‌بندی تصویر**

Malware Classification Based on Image Segmentation

نگارندگان

امیرحسین محمدزاده کسری منتظری امیرمهدی طهماسبی

استاد درس

دکتر بردیا صفائی

دستیار آموزشی

علی اثنی‌عشری

شهریور ۱۴۰۵

فهرست مطالب

۱	شناسنامه مقاله و چکیده مدیریتی	۲
۲	صورت مسئله، انگیزه و جایگاه در ادبیات	۳
۳	روش پیشنهادی مقاله	۴
۴	بستر آزمایش و پیکربندی مقاله	۵
۵	مجموعه داده و پیش پردازش	۶
۶	نتایج گزارش شده در مقاله	۷
۶	نقد و ارزیابی انتقادی مقاله	۸
۸	بازپاده سازی و بازتولید نتایج روی BIG 2015	۹
۱۰	انتقال به دامنه نهفته: مجموعه داده ARM/Zephyr	۱۰
۱۲	بهبودهای فاز چهارم و مطالعه حذفی	۱۱
۱۷	بازارزیابی انتقادی نتایج خودمان	۱۲
۲۰	جمع بندی، محدودیت ها و کارهای آینده	مراجع
۲۱		

۱ شناسنامه مقاله و چکیده مدیریتی

مقاله مورد بررسی در جدول ۱ معرفی شده است. این اثر یک پیش چاپ arXiv است که برای ارسال به Elsevier آماده شده و داوری همتا را پشت سر نگذاشته؛ همین نکته باید در وزن دهی به ادعاهای آن لحاظ شود. نشانی مخزنی که پانویس صفحه نخست برای کد و داده اعلام کرده دیگر پاسخ نمی دهد، ولی مخزن نویسنده با نام تازه maisseg در همان حساب پابرجاست. آنچه در آن منتشر شده پیاده سازی چارچوب بعدی نویسنده است به همراه جدول بخش های استخراج شده BIG 2015، و نه خط لوله S1 تا S5 این مقاله؛ بنابراین بازتولید جدول ۵ همچنان تنها از روی متن ممکن است و در §۸ به تفصیل به این تفاوت ها می پردازیم.

جدول ۱: شناسنامه کتاب شناختی مقاله مورد بررسی

عنوان	Malware Classification Based on Image Segmentation
نویسنده	Wanhui Nie (نویسنده مسئول و تنها نویسنده)، دانشگاه صنعتی لانتزو، چین
نوع و سال	پیش چاپ arXiv:2406.03831v1، ۶ ژوئن ۲۰۲۴، هشت صفحه، ارسال شده به Elsevier
کلیدواژه ها	دسته بندی بدافزار، مصورسازی بدافزار ^۱ ، تحلیل ایستا ^۲ ، یادگیری عمیق
مجموعه داده	Microsoft Malware Classification Challenge (BIG 2015) [۱]
دسترسی به کد	نشانی پانویس مقاله از کار افتاده است؛ مخزن نویسنده با نام maisseg در دسترس است ولی چارچوب بعدی او را پیاده می کند

روش های «مصورسازی بدافزار» جریان بایستی یک فایل اجرایی را به عنوان شدت روشنایی پیکسل تفسیر می کنند و مسئله دسته بندی بدافزار را به دسته بندی تصویر فرو می کاهند [۲]. نقطه ضعف شناخته شده این خانواده آن است که مهاجم می تواند با جابه جایی بخش ها^۳ یا تزییق داده زائد، چیدمان فضایی تصویر را دستکاری کند و طبقه بند را گمراه سازد.

ایده مرکزی مقاله ساده و روشن است: به جای نگاشت کل فایل به یک تصویر واحد، تصویر خاکستری بر اساس نوع بخش قطعه بندی شود و هر زیر تصویر به عنوان یک کانال جداگانه به شبکه پیچشی برود. دو صورت بندی پیشنهاد می شود: Split که هر بخش را فشرده و مستقل از جایگاهش ذخیره می کند، و Mask که موقعیت اصلی بخش را حفظ ولی بقیه تصویر را صفر می کند. در کنار این، سه طرح هم ترازای عرض مقایسه و عرض تصویر به عنوان یک ابرپارامتر مستقل معرفی می شود. ارزیابی روی BIG 2015 با VGG16 [۳] و ResNet50 [۴] و ۲۰ پیکربندی انجام شده و سنجه اصلی، زیان لگاریتمی چندکلاسه^۴ سرور ارزیابی کگل است؛ بهترین عدد گزارش شده ۰/۰۲۶۵ برای ResNet50 روی S3 (عرض ثابت ۱۰۲۴) است.

این گزارش دو بخش دارد. بخش نخست (§۱ تا §۷) مقاله را تحلیل و نقد می کند و هر ایراد را تنها بر پایه محتوای منتشر شده خود مقاله مستند می سازد. بخش دوم (§۸ تا §۱۲) کار تیم ما در فازهای سوم و چهارم را گزارش می کند: بازتولید کامل ۲۰ پیکربندی مقاله روی BIG 2015، انتقال روش به دامنه سیستم های نهفته با یک مجموعه داده ELF از Zephyr روی ARM، و یک مطالعه حذفی^۵ روی مجموعه ای از بهبودها. در بخش دوم همان سخت گیری را به کار خودمان نیز اعمال کرده ایم و نشان می دهیم پروتکل ارزیابی اولیه مان معیوب بوده و اعداد اصلاح شده چه تصویر متفاوتی می سازند.

۲ صورت مسئله، انگیزه و جایگاه در ادبیات

مسئله مقاله انتساب خانواده بدافزار^۶ است، نه تشخیص دودویی بدافزار از نرم افزار سالم: ورودی فایل دودویی یک برنامه اجرایی و خروجی توزیع احتمال روی ۹ خانواده است. این تمایز مهم است، چون تمام نمونه های BIG 2015 بدافزاراند و هیچ کلاس سالمی در مسئله وجود ندارد؛ پس نتایج مقاله چیزی درباره نرخ هشدار کاذب یک سامانه واقعی نمی گویند.

انگیزه روش شناختی از دو مشاهده ساخته می شود. نخست، به دلیل سازوکار هم ترازای فایل^۷ در قالب PE، انتهای هر بخش با تعدادی بایت صفر پر می شود و چون تعداد این بایت ها ثابت نیست، مرز میان بخش ها در تصویر خاکستری مبهم می ماند. دوم، مهاجم می تواند ترتیب بخش ها را تغییر دهد یا داده زائد تزییق کند و چیدمان فضایی تصویر را که مبنای کار

¹Malware Visualization

²Static Analysis

³Sections

⁴Multi-class Logarithmic Loss

⁵Ablation Study

⁶Malware Family Attribution

⁷File Alignment

روش‌های پیشین است بر هم بزنند.

Nataraj و همکاران [۲] نخستین بار تبدیل دنباله بایتی به تصویر خاکستری را پیشنهاد کردند و جدول هم‌ترازی عرض بر حسب اندازه فایل از همان کار می‌آید. Vasan و همکاران [۵] تصویر خاکستری را رنگی کردند و یک شبکه پیچشی تنظیم‌شده را روی آن آموزش دادند. نزدیک‌ترین کار، Xiao و همکاران [۶] است که برای هر بخش یک کادر رنگی به تصویر می‌افزایند تا اطلاعات توزیع بخش‌ها برجسته شود؛ ایراد مقاله به این راهکار آن است که کادر رنگی بخشی از پیکسل‌های واقعی را می‌پوشاند. Chaganti و همکاران [۷] نیز پیش‌تر نشان داده بودند عرض ثابت سودمند است، ولی دلیل آن را تحلیل نکرده بودند.

جایگاه مقاله در این نقشه روشن است: به جای افزودن نشانه بصری به تصویر (راهکار Xiao)، خود تصویر بر اساس نوع بخش تجزیه می‌شود و زیرتصویرها به کانال‌های مستقل می‌روند؛ یعنی مرزبندی بخش‌ها به جای استنتاج از روی تصویر، در ساختار داده ورودی کدگذاری می‌گردد. ادعای «استقلال فضایی» روش نیز از همین جا می‌آید. مقاله سه سهم برای خود برمی‌شمارد: صورت‌بندی Mask/Split، نشان دادن اینکه زیرتصویرهای بخش‌ها به تنهایی نیز ویژگی‌های دسته‌بندی مطلوبی دارند، و طرح عرض تصویر به عنوان یک ابرپارامتر مستقل. سهم نخست تازه و به روشنی متمایز است. سهم دوم یک مشاهده تجربی ارزشمند است ولی، چنان‌که در §۷ و §۱۱-۴ نشان خواهیم داد، پشتوانه عددی آن شکننده‌تر از چیزی است که متن القا می‌کند. سهم سوم عملاً تأیید مشاهده پیشین Chaganti است؛ مقاله به این تقدم اذعان می‌کند، اما تحلیل وعده‌داده‌شده درباره چرایی اثر عرض ارائه نمی‌شود و بحث در سطح توصیفی می‌ماند.

۳ روش پیشنهادی مقاله

۳-۱ خط لوله

محتوای دودویی فایل به صورت دنباله‌ای از بایت‌های بدون علامت خوانده و هر بایت یک پیکسل خاکستری تلقی می‌شود؛ دنباله با عرضی مشخص به ماتریس دوبعدی تا می‌خورد، محدوده بایتی هر بخش به یک زیرتصویر نگاشته می‌شود و همه زیرتصویرها پس از تغییر مقیاس به 224×224 به عنوان کانال‌های یک تانسور ورودی روی هم می‌نشینند. مقاله به درستی تأکید می‌کند که نوع یک بخش را نمی‌توان از نام آن نتیجه گرفت (چون نام قابل مبهم‌سازی است) و ترکیب نام و صفات^۸ مبنا قرار می‌گیرد؛ برای BIG 2015 بخش‌ها به شش رده HEADER، .text، .rdata، .data، .rsrc و «سایر» تقسیم می‌شوند.

۳-۲ دو راهبرد قطعه‌بندی و پنج طرح داده


تفاوت دو راهبرد در آن است که با فضای بیرون بخش هدف چه می‌کنند (شکل ۱). در Split پیکسل‌های هر بخش بیرون کشیده و فشرده بازچیده می‌شوند؛ چیدمان فضایی بخش نسبت به کل فایل به کلی دور ریخته می‌شود و ادعای مقاومت در برابر بازآرایی بخش‌ها دقیقاً از همین جا برمی‌خیزد. در Mask زیرتصویر هم‌اندازه تصویر اصلی می‌ماند و تنها پیکسل‌های بخش هدف نمایش داده می‌شوند؛ اطلاعات مکانی حفظ می‌شود ولی به بهای تُنکی شدید، که مقاله خود آن را علت افت S5 در حالت مستقل می‌داند.

بر این پایه پنج طرح داده تعریف می‌شود. سه طرح نخست به هم‌ترازی عرض مربوطاند: S1 عرض را از جدول اندازه فایل Nataraj [۲] می‌گیرد (۳۲ برای فایل‌های زیر ۱۰ کیلوبایت تا ۱۰۲۴ برای بزرگ‌تر از یک مگابایت)، S2 عرض را ریشه دوم اندازه فایل می‌گذارد و بیشترین تنوع عرض را می‌سازد، و S3 عرض را برای همه روی ۱۰۲۴ ثابت می‌کند. S4 و S5 همان Split و Mask‌اند و هر دو روی عرض ثابت ۱۰۲۴ بنا می‌شوند. در S1 تا S3 تصویر تک‌کاناله سه بار تکرار می‌شود تا با ورودی شبکه‌های از پیش‌آمोخته سازگار شود؛ در S4 و S5 هر زیرتصویر یک کانال مستقل است.

۳-۳ معماری‌ها

مقاله از VGG16 [۳] و ResNet50 [۴] از پیش‌آمोخته روی ImageNet استفاده می‌کند و برای پیکربندی‌های بیش از سه کانال، لایه پیچشی ورودی را بازتعریف می‌کند. مقاله در بخش محدودیت‌ها می‌پذیرد که این کار انتقال وزن‌های لایه نخست را

^۸Characteristics



شکل ۱: دو راهبرد قطعه‌بندی از شکل ۳ مقاله: Split (ردیف بالا) هر بخش را فشرده و مستقل از جایگاهش بازمی‌چیند و Mask (ردیف پایین) موقعیت اصلی را نگه می‌دارد و بقیه بوم را صفر می‌کند.

مختل می‌سازد، اما چنان‌که در §۷ خواهیم دید، پیامد آن را در تفسیر جدول نتایج لحاظ نمی‌کند.

۴ بستر آزمایش و پیکربندی مقاله

آزمایش‌ها روی یک ماشین با پردازنده Xeon Platinum 8255C و کارت گرافیک NVIDIA RTX 2080 Ti با ۱۱ گیگابایت حافظه انجام شده‌اند. بهینه‌ساز در هر دو مدل گرادین کاهشی تصادفی^۹ با تابع زیان آنتروپی متقاطع است و ابرپارامترها در جدول ۲ آمده‌اند.

جدول ۲: ابرپارامترهای گزارش‌شده مقاله (بازآوری جدول ۴ مقاله)

مدل	دوره	اندازه دسته	نرخ یادگیری	زمان‌بند	کاهش وزن	تکانه
VGG16	۲۰	۸	۰/۰۰۱	ندارد	۰/۰۰۰۵	۰/۹
ResNet50	۱۵	۶۴	۰/۰۱	نمایی با نرخ ۰/۹	۰/۰۰۶	۰/۹

دو ملاحظه در همین جدول دیده می‌شود. نخست، کاهش وزن ۰/۰۰۶ برای ResNet50 یک مرتبه بزرگی بیش از مقادیر متعارف در تنظیم دقیق شبکه‌های از پیش‌آمورخته است و هیچ توضیحی درباره انتخاب آن داده نمی‌شود. دوم، تقریباً همه ابرپارامترها میان دو معماری متفاوت‌اند؛ بنابراین هر مقایسه‌ای میان VGG16 و ResNet50 در جدول نتایج، مقایسه دو رویه آموزشی است و نه دو معماری. مقاله تنها تفاوت اندازه دسته را با محدودیت حافظه توجیه می‌کند.

مقاله دو سنجه گزارش می‌کند. نخست صحت روی مجموعه آموزش، که خود نویسنده می‌پذیرد سنجه ضعیفی است. دوم زیان لگاریتمی چندکلاسه^{۱۰} روی مجموعه آزمون بدون برچسب که با ارسال پیش‌بینی‌ها به سرور کگل محاسبه می‌شود:

$$\text{logloss} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y_{ij} \log(p_{ij}) \quad (1)$$

که در آن N تعداد نمونه‌های آزمون، M تعداد خانواده‌ها، y_{ij} نشانگر دودویی عضویت و p_{ij} احتمال پیش‌بینی شده است. سرور کگل این مقدار را روی دو زیرمجموعه جدا می‌دهد: نمره عمومی^{۱۱} روی ۳۰٪ نمونه‌ها و نمره خصوصی^{۱۲} روی ۷۰٪ باقی‌مانده. مقاله نمره خصوصی را نتیجه نهایی می‌گیرد که انتخاب درستی است.

استفاده از یک سرور ارزیابی بیرونی با برچسب‌های پنهان، نقطه قوت روش شناختی مقاله است و امکان نشت داده آزمون را از میان می‌برد؛ ولی چون هر ۲۰ پیکربندی روی همان مجموعه آزمون ارزیابی و سپس بهترین‌ها گزارش شده‌اند، عدد گزینش شده به‌طور نظام‌مند خوش‌بینانه است. این نکته را در §۷ پی می‌گیریم.

^۹Stochastic Gradient Descent (SGD)

^{۱۰}Multi-class Logarithmic Loss

^{۱۱}Public Score

^{۱۲}Private Score

۵ مجموعه داده و پیش پردازش


ارزیابی تنها روی Microsoft Malware Classification Challenge [۱] انجام شده است: ۱۰,۸۶۸ نمونه آموزش برچسب دار و ۱۰,۸۷۳ نمونه آزمون بدون برچسب از ۹ خانواده. هر نمونه یک فایل bytes. (محتوای دودویی) و یک فایل asm. (خروجی دیس اسمبلر IDA) دارد. توزیع کلاس ها به شدت نامتوازن است، از ۲,۹۴۲ نمونه برای Kelihos_ver3 تا تنها ۴۲ نمونه برای Simda؛ مقاله این را گزارش می کند ولی هیچ تدبیری برای آن نمی اندیشد و هیچ سنجه متوازی ارائه نمی دهد.

۱-۵ یک وابستگی مهم که کم رنگ مانده است

فایل های bytes. به دلایل امنیتی فاقد PE-Header هستند، پس جدول بخش ها را نمی توان از آن ها استخراج کرد؛ مقاله این مشکل را با خواندن نشانگرهای ابتدای هر بخش از فایل asm. حل می کند. پیامد آن است که خط لوله پیشنهادی، برخلاف آنچه چارچوب بندی مقاله القا می کند، صرفاً بایت محور نیست و به خروجی یک دیس اسمبلر تجاری وابسته است. این نکته از آن جهت اهمیت دارد که مقاله در بخش کارهای مرتبط، دقیقاً پرهیز از دیس اسمبل را به عنوان مزیت خانواده روش های مصورسازی برمی شمارد؛ یعنی روش پیشنهادی بخشی از همان هزینه ای را باز می گرداند که مصورسازی قرار بود حذف کند و در برابر همان مبهم سازی هایی آسیب پذیر می شود که تحلیل ایستا را هدف می گیرند. مقاله این وابستگی را پنهان نمی کند، اما آن را به عنوان محدودیت هم صورت بندی نمی کند. به همین دلیل، رده HEADER نیز برای این مجموعه داده بی اثر است و جدول ۱ مقاله در عمل تنها برای چهار بخش به کار می آید.

۲-۵ پیش پردازش

بایت های ناشناخته (??) به جای حذف، یکنواخت به صفر نگاشته می شوند؛ انتخاب ساده و قابل دفاعی است، هرچند این پیکسل های صفر با پیکسل های صفر ناشی از هم ترازی فایل تمیز ناپذیر می شوند. در S4 و S5 عرض پایه پیش از قطعه بندی روی ۱۰۲۴ ثابت می شود تا اثر عرض از اثر قطعه بندی جدا بماند؛ تصمیم روش شناختی درستی است. شکل ۲ نشان می دهد که چرا عرض اصلاً اهمیت دارد: یک نمونه واحد زیر سه طرح هم تراز، سه بافت کاملاً متفاوت تولید می کند.



شکل ۲: اثر طرح هم تراز بر تصویر خاکستری، از شکل ۴ مقاله. هر ردیف یک نمونه واحد است که با سه طرح S1، S2 و S3 رستر شده است.

نکته ای که مقاله درباره آن سکوت می کند، سرنوشت نمونه هایی است که یک بخش خاص را ندارند؛ در پیکربندی های چندکاناله باید کانال متناظر با چیزی پر شود و متن این حالت را پوشش نمی دهد. در بازپیاپی سازی خودمان (۸) این حالت را با تولید یک کانال تمام صفر در زمان پیش پردازش مدیریت کردیم؛ انتخابی که ناگزیر بود ولی خودسرانه است و یکی از نقاطی است که بازتولید بیت به بیت مقاله را ناممکن می سازد.

۶ نتایج گزارش شده در مقاله

جدول ۵ مقاله ۲۰ پیکربندی را گزارش می‌کند (شش برای VGG16 و چهارده برای ResNet50) و جدول ۳ چکیده آن را بر حسب خانواده طرح می‌دهد. نخستین مشاهده این است که ستون صحت آموزش برای همه ۲۰ ردیف میان ۹۹/۳۰٪ و ۱۰۰٪ است؛ یعنی هیچ قدرت تفکیکی ندارد و تمام بار مقایسه روی یک عدد واحد، یعنی زیان لگاریتمی، می‌افتد.

جدول ۳: چکیده نتایج گزارش شده مقاله بر حسب خانواده طرح (زیان لگاریتمی، نمره خصوصی؛ کمتر بهتر است)

خانواده طرح	تعداد پیکربندی	بهترین	بدترین	میانگین
S3-S1 (تصویر خام)	۶	۰/۰۲۶۵	۰/۰۵۴۷	۰/۰۳۷۸
S4 (Split)	۶	۰/۰۳۲۰	۰/۰۵۸۷	۰/۰۴۴۷
S5 همراه تصویر خام	۵	۰/۰۲۷۹	۰/۰۵۲۱	۰/۰۳۵۳
S5 بدون تصویر خام	۳	۰/۰۴۴۶	۰/۰۸۸۹	۰/۰۶۱۳

مقاله چهار نتیجه از این جدول بیرون می‌کشد. نخست، **عرض ثابت بهتر است**: روی ResNet50 ترتیب S3 با ۰/۰۲۶۵، سپس S1 با ۰/۰۳۱۶ و سپس S2 با ۰/۰۳۳۰ برقرار است و S2 که بیشترین تنوع عرض را دارد روی هر دو معماری بدترین طرح خام است. دوم، **قطعه‌بندی Split کافی است**: روی ResNet50، S4 کارایی «مشابه» S3-S1 دارد، پس حتی با نادیده گرفتن کامل چیدمان فضایی هم می‌توان به نتایج خوب رسید. سوم، **Mask تنها با تصویر خام کار می‌کند**: S5 به‌دلیل تُنگی ضعیف است ولی ترکیب آن با تصویر خام عرض ثابت به ۰/۰۲۷۹ می‌رسد. چهارم، **بخش‌ها سهم نابرابر دارند**: text. مهم‌ترین بخش است اما حتی بدون آن هم کارایی قابل قبول می‌ماند، و rsr. ویژگی‌های دسته‌بندی بسیار خوبی نشان می‌دهد که مقاله آن را به اشتراک منابعی مانند آیکون و منو میان گونه‌های یک خانواده نسبت می‌دهد.

نکته مهم آن است که بهترین ردیف جدول از آن S3 است و هیچ پیکربندی قطعه‌بندی از آن جلو نمی‌زند؛ یعنی ادعای مقاله «بهترین صحت» نیست، بلکه رسیدن به نتیجه‌ای نزدیک در ازای استقلال از چیدمان فضایی است. این تمایز در §۱۱-۴ تعیین‌کننده خواهد بود.

۷ نقد و ارزیابی انتقادی مقاله

جدول ۴: دسته‌بندی ایرادهای استخراج شده از متن مقاله

مورد	نوع	شاهد در خود مقاله
نبود تکرار و بازه اطمینان برای رتبه‌بندی ۲۰ پیکربندی	خطای روش‌شناختی	جدول ۵: پنج ردیف برتر در بازه ۰/۰۲۶۵-۰/۰۲۹۲
مقایسه دو معماری با چهار ابرپارامتر متفاوت	خطای روش‌شناختی	جدول ۴
درهم‌آمیختگی اثر بازنمایی با از دست رفتن پیش‌آموزش لایه ورودی	خطای روش‌شناختی	بخش ۵ (محدودیت‌ها) و جدول ۵
ادعای مقاومت در برابر مبه‌م‌سازی بدون آزمایش	خطای روش‌شناختی	چکیده و بخش ۶ در برابر بخش ۴
سنجه واحد و حساس به نامتوازن کلاس‌ها	خطای روش‌شناختی	جدول ۲ در برابر بخش ۴/۴
سیاست کانال‌های غایب مشخص نیست	کاستی گزارش‌دهی	بخش ۴/۲
نبود بذر تصادفی، زمان اجرا و سنجه‌های درون‌کلاسی	کاستی گزارش‌دهی	بخش ۴/۴ و جدول ۵
نبود مقایسه عددی با کارهای پیشین	کاستی گزارش‌دهی	بخش ۶ در برابر بخش ۲
از کار افتادن نشانی مخزن اعلام‌شده و نبود کد این مقاله در مخزن جایگزین	کاستی گزارش‌دهی	پانویس صفحه ۱ در برابر مخزن maisg
وابستگی به دیس‌اسمبلر برای استخراج جدول بخش‌ها	محدودیت دامنه	بخش ۴/۱
ارزیابی روی یک مجموعه داده و تنها قالب PE	محدودیت دامنه	بخش ۴/۱

۱-۷ نقاط قوت

ایده مرکزی ساده، تازه و به‌خوبی انگیزه‌مند است و جای خالی مشخصی را در ادبیات پر می‌کند. سنجه ارزیابی بیرونی با برچسب‌های پنهان (سرور کگل) امکان نشت داده آزمون را از میان می‌برد و ثابت نگه داشتن عرض پایه در S4 و S5، اثر عرض را از اثر قطعه‌بندی جدا می‌کند. بخش محدودیت‌ها صادقانه نوشته شده و روش چنان روشن توصیف شده که بازپیاپی‌سازی مستقل از روی متن ممکن بود.

۲-۷ خطاهای روش شناختی

الف. رتبه‌بندی‌ها پشتوانه آماری ندارند. ۲۰ پیکربندی روی همان مجموعه آزمون ارزیابی و سپس بهترین‌ها برجسته شده‌اند. پنج پیکربندی برتر ResNet50 در بازه ۰/۰۲۶۵ تا ۰/۰۲۹۲ (پهنایی حدود ده درصد نسبی) قرار دارند و هیچ تکرار، انحراف معیار یا بازه اطمینانی گزارش نشده است. پس گزاره «S3 بهتر از S1 است» که یکی از دو نتیجه‌گیری اصلی مقاله است، از نوسان تصادفی تفکیک‌پذیر نیست؛ ایراد متوجه قطعیت لحن است نه اصل مشاهده.

ب. مقایسه معماری‌ها مخدوش است. دو معماری در تعداد دوره، اندازه دسته، نرخ یادگیری اولیه و وجود زمان‌بند تفاوت دارند (جدول ۲)؛ پس جمله‌هایی از نوع «S3 روی ResNet50 به‌مراتب بهتر از VGG16 عمل می‌کند» دو رویه آموزشی را مقایسه می‌کنند، نه دو معماری را.

پ. اثر بازنمایی با پیش‌آموزش درهم‌آمیخته است. در S1 تا S3 لایه پیش‌بینی نخست وزن‌های ImageNet را دست‌نخورده نگه می‌دارد، ولی در پیکربندی‌های چهار و پنج کاناله از نو مقداردهی می‌شود. مقاله این را در بخش محدودیت‌ها می‌پذیرد اما در نتیجه‌گیری از جدول ۵ لحاظ نمی‌کند؛ پس اختلاف S4 چندکاناله با S3-S1 را نمی‌توان صرفاً به بازنمایی نسبت داد. حتی در حالت سه‌کاناله نیز سه زیرتصویر با معنای کاملاً متفاوت از فیلترهایی عبور می‌کنند که برای همبستگی کانال‌های رنگی آموخته شده‌اند.

ت. ادعای محوری مقاومت، سنجیده نشده است. چکیده و نتیجه‌گیری بر «استقلال فضایی» و امید به مقاومت در برابر مبهم‌سازی تأکید می‌کنند، ولی این ادعا سنجیده نمی‌شود؛ در حالی که آزمون لازم پرهزینه نبود: کافی بود ترتیب بخش‌ها در نمونه‌های آزمون جابه‌جا یا داده زائد تزریق شود و افت S3-S1 با S4 مقایسه گردد. مقاله می‌نویسد «اعتبارسنجی بیشتری لازم است» و این صداقت ارزشمند است، اما چارچوب‌بندی چکیده قوی‌تر از شواهد است. شاهد غیرمستقیمی هم در دست است: چارچوب بعدی همین نویسنده (مخزن maisseg) آزمون مقاومت در برابر بازآرایی بخش‌ها را صراحتاً به‌عنوان یکی از قابلیت‌های خود فهرست می‌کند؛ یعنی خود نویسنده نیز این شکاف را واقعی دانسته و در کار بعدی به آن پرداخته است.

ث. سنجه با ساختار مسئله همخوان نیست. زیان لگاریتمی بر نمونه میانگین می‌گیرد، پس در این مجموعه داده نامتوازن، عملکرد روی خانواده‌های کوچک اثری بر عدد نهایی ندارد؛ مدل می‌تواند Simda را با ۴۲ نمونه به‌کلی از دست بدهد و همچنان زیان لگاریتمی عالی بدهد، در حالی که افزودن F1 کلان هزینه‌ای نداشت.

۳-۷ کاستی‌های گزارش‌دهی

ستون صحت آموزش برای هر ۲۰ ردیف اشباع است؛ خود مقاله می‌نویسد این سنجه گویا نیست ولی آن را نگه می‌دارد. سیاست برخورد با نمونه‌های فاقد یک بخش مشخص نشده و بذر تصادفی، زمان آموزش و استنتاج و سنجه‌های درون‌کلاسی گزارش نشده‌اند. هیچ عدد مرجعی از کارهای پیشین نیامده در حالی که نتیجه‌گیری ادعای «کارایی قابل مقایسه» دارد، و وعده تحلیل چرایی اثر عرض هم برآورده نمی‌شود. سرانجام، نشانی مخزنی که پانویس صفحه نخست اعلام کرده از کار افتاده و مخزن جایگزین، کد این مقاله را در بر ندارد بلکه چارچوب بعدی نویسنده است (۸).

۴-۷ محدودیت‌های دامنه و جمع‌بندی

ارزیابی تنها روی یک مجموعه داده و قالب PE انجام شده و معنانشناسی بخش‌ها (به‌ویژه نقش rsrsrc). ویژه ویندوز است و منتقل نمی‌شود؛ BIG 2015 هیچ نمونه سالمی ندارد، پس نتایج چیزی درباره نرخ هشدار کاذب نمی‌گویند؛ و وابستگی به دیس‌اسمبلر (۵) بخشی از هزینه‌ای را که مصورسازی قرار بود حذف کند بازمی‌گرداند.

جدول ۴ ایرادها را دسته‌بندی می‌کند. ارزیابی کلی ما این است که ایده ارزش‌پیگیری دارد ولی شواهد، بار ادعاها را تحمل نمی‌کنند و دو پرسش کلیدی بی‌پاسخ می‌ماند: آیا قطعه‌بندی واقعاً مقاومت بیشتری در برابر مبهم‌سازی می‌دهد، و آیا به دامنه‌های دیگر منتقل می‌شود؛ پرسش دوم را در بخش دوم تجربی می‌آزماییم.

۸ بازپایاده‌سازی و بازتولید نتایج روی BIG 2015

۱-۸ پیاده‌سازی

نشانی مخزنی که مقاله اعلام کرده از کار افتاده و مخزن جایگزین نویسنده، چنان‌که در §۸-۳ نشان می‌دهیم، خط لوله این مقاله را پیاده نمی‌کند؛ پس بازتولید تنها از روی توصیف متن ممکن بود. این با هدف فاز سوم درس نیز هم‌خوان است که بازنویسی مستقل روش را می‌خواهد. کل خط لوله را از ابتدا در PyTorch پیاده‌سازی کردیم و آن را به‌صورت یک بسته پایتونی با رابط خط فرمان سازمان دادیم. این پیاده‌سازی پنج مؤلفه دارد: دریافت و آماده‌سازی داده، پیش‌پردازش و تولید بازنمایی‌های S1 تا S5، ساخت مدل، آموزش و ارزیابی، و تولید فایل ارسال به کگل.

یک تصمیم طراحی که بعداً برای فاز چهارم تعیین‌کننده شد، جدا کردن کامل فرادادهٔ مجموعه‌داده از منطق برنامه بود: کلاس‌ها، بخش‌های هدف، تعریف کانال‌ها و فهرست پیکربندی‌ها همگی در یک فایل JSON توصیف می‌شوند؛ آزمایش‌های این بخش با پیکربندی big2015.json اجرا شده‌اند. به این ترتیب افزودن یک مجموعه‌داده تازه با قالب و معنانشناسی بخش‌های متفاوت، بدون دست زدن به کد آموزش ممکن شد.

۲-۸ میزان وفاداری به مقاله و انحراف‌های ناگزیر

ابریارمترهای جدول ۲، دو معماری، پنج طرح داده، عرض پایه ۱۰۲۴ برای S4 و S5، قاعده نگاشت بایت‌های ?? به صفر و اندازه نهایی 224×224 همگی عیناً از مقاله گرفته شده‌اند. پروتکل ارزیابی نیز همان است: پیش‌بینی روی ۱۰,۸۷۳ نمونه آزمون بدون برچسب و ارسال به سرور کگل برای دریافت نمره عمومی و خصوصی.

سه انحراف ناگزیر وجود دارد که برای شفافیت ثبت می‌شوند. نخست، سیاست کانال‌های غایب که در مقاله مشخص نشده و ما آن را با کانال تمام‌صفر پیاده کردیم. دوم، بهنجارسازی کانال‌های چهارم و پنجم که میانگین ۰/۵ و انحراف معیار ۰/۲۲۵ می‌گیرند، چون ImageNet تنها برای سه کانال مقدار مرجع دارد. سوم، فعال بودن دقت مختلط^{۱۳} برای کاهش زمان اجرا. بذر تصادفی را روی ۴۲ ثابت کردیم؛ مقاله بذری گزارش نکرده است.

۳-۸ مقایسه با کد منتشرشده نویسنده

مخزن maisseg در حساب نویسنده در دسترس است، ولی آنچه در آن منتشر شده چارچوب بعدی اوست: به‌جای رستر خاکستری و قطعه‌بندی Mask/Split، هر فایل به یک نقشه ویژگی سه‌کاناله نگاشته می‌شود که سه کانال آن میانگین، انحراف معیار و آنتروپی هر قطعه بایتی‌اند و سهم هر بخش از بوم برابر توزیع می‌شود. بنابراین جدول ۵ مقاله را نمی‌توان از روی این مصنوع بازتولید کرد و بازنویسی از روی متن ناگزیر بود. جدول ۵ پارامترهای کلیدی سه منبع را کنار هم می‌گذارد.

جدول ۵: مقایسه پارامترهای کلیدی روی BIG 2015: متن مقاله، کد منتشرشده نویسنده و پیاده‌سازی ما

مؤلفه	متن مقاله (جدول ۴)	کد منتشرشده (maiseg)	پیاده‌سازی ما
بازنمایی ورودی	رستر خاکستری، طرح‌های S1 تا S5	نقشه RGB از میانگین، انحراف معیار و آنتروپی قطعه‌ها با سهم برابر بخش‌ها	رستر خاکستری، طرح‌های S1 تا S5 مطابق متن
معماری‌ها	ResNet50 و VGG16	تنها ResNet50	ResNet50 و VGG16
نرخ یادگیری	۰/۰۱ / ۰/۰۰۱	۰/۰۱	۰/۰۱ / ۰/۰۰۱
کاهش وزن	۰/۰۰۶ / ۰/۰۰۰۵	۰/۰۰۰۵	۰/۰۰۶ / ۰/۰۰۰۵
دوره و اندازه دسته	۲۰ با دسته ۸ / ۱۵ با دسته ۶۴	۲۰ با دسته ۶۴	مطابق مقاله، به‌علاوه اجرای ۱۰ دوره‌ای مطابق مقاله
زمان‌بند	ندارد / نمایی با نرخ ۰/۹	نمایی با نرخ ۰/۹	مطابق مقاله
بهنجارسازی ورودی	گزارش نشده	ندارد (تنها تبدیل به تانسور)	بهنجارسازی ImageNet
پروتکل ارزیابی	زیان لگاریتمی کگل، نمره خصوصی	صحت اعتبارسنجی متقابل ۱۰-تایی روی ۱۰,۸۶۸ نمونه برچسب‌دار	زیان لگاریتمی کگل، نمره عمومی و خصوصی
بذر تصادفی	گزارش نشده	متغیر بذر استفاده ولی تعریف نشده	۴۲

سه تفاوت از این جدول اهمیت عملی دارد. نخست، کاهش وزن ResNet50 در متن مقاله ۰/۰۰۶ است ولی در کد خود نویسنده ۰/۰۰۵؛ ما متن را مبنا گرفتیم تا بازتولید به توصیف منتشرشده وفادار بماند. دوم، کد نویسنده هیچ بهنجارسازی ورودی ندارد، در حالی که استفاده از ستون فقرات از پیش‌آموخته روی ImageNet معمولاً بهنجارسازی متناظر را ایجاب

¹³Automatic Mixed Precision


می‌کند. سوم، پروتکل ارزیابی دو منبع یکی نیست: عدد ۹۹/۴۹٪ که در توضیحات مخزن برای BIG 2015 آمده صحت اعتبارسنجی متقابل روی مجموعه برجسب‌داراست و با زیان لگاریتمی مجموعه آزمون پنهان کگل در جدول ۵ قابل مقایسه نیست.

۴-۸ نتایج

جدول ۶ هر ۲۰ پیکربندی جدول ۵ مقاله را در کنار نتایج ما قرار می‌دهد و شکل ۳ همین داده را به صورت بصری نشان می‌دهد. ستون آخر، اجرای کوتاه‌شده با ۱۰ دوره است که برای سنجش حساسیت به بودجه آموزش انجام دادیم.

جدول ۶: بازتولید ۲۰ پیکربندی مقاله روی BIG 2015؛ همه اعداد زیان لگاریتمی چندکلاسه‌اند (کمتر بهتر است)

مدل	پیکربندی	مقاله	ما، عمومی	ما، خصوصی	اختلاف	ما، ۱۰ دوره
VGG16	S1	۰/۰۴۰۱	۰/۰۵۲۳۴	۰/۰۵۳۳۷	+۰/۰۱۳۳	۰/۰۴۴۲۳
	S2	۰/۰۵۴۷	۰/۰۵۳۱۴	۰/۰۵۰۴۶	-۰/۰۰۴۲	۰/۰۴۶۲۷
	S3	۰/۰۴۱۱	۰/۰۳۵۴۰	۰/۰۴۳۶۵	+۰/۰۰۲۶	۰/۰۴۴۸۹
	S4 (.text + .rdata + .rsrc)	۰/۰۵۷۷	۰/۰۹۱۵۲	۰/۰۹۲۲۶	+۰/۰۰۳۴۶	۰/۰۸۸۶۱
	S5 (imgs-1024 + .text + .rsrc)	۰/۰۵۲۱	۰/۰۶۱۰۱	۰/۰۵۷۰۹	+۰/۰۰۵۰	۰/۰۵۱۲۸
	S5 (.text + .rdata + .rsrc)	۰/۰۸۸۹	۰/۲۲۸۹۴	۰/۲۱۸۸۳	+۰/۱۲۹۹	۰/۱۲۲۹۵
ResNet50	S1	۰/۰۳۱۶	۰/۰۳۴۷۷	۰/۰۳۶۰۱	+۰/۰۰۴۴	۰/۰۳۷۳۵
	S2	۰/۰۳۳۰	۰/۰۳۳۳۲	۰/۰۳۹۱۶	+۰/۰۰۶۲	۰/۰۴۶۴۱
	S3	۰/۰۲۶۵	۰/۰۳۲۷۹	۰/۰۳۴۴۶	+۰/۰۰۸۰	۰/۰۳۸۰۰
	S4 (.rdata + .data + .rsrc)	۰/۰۵۸۷	۰/۱۰۹۱۴	۰/۰۸۵۵۹	+۰/۰۰۲۶۹	۰/۰۸۷۴۷
	S4 (.text + .data + .rsrc)	۰/۰۳۸۳	۰/۰۸۷۶۱	۰/۰۸۲۴۴	+۰/۰۰۴۴۱	۰/۰۸۷۶۱
	S4 (.text + .rdata + .data)	۰/۰۴۵۲	۰/۱۱۷۹۶	۰/۰۹۳۷۱	+۰/۰۰۴۸۵	۰/۰۹۷۹۳
	S4 (.text + .rdata + .data + .rsrc)	۰/۰۳۶۴	۰/۰۹۵۲۸	۰/۰۸۳۸۸	+۰/۰۰۴۷۵	۰/۰۷۱۸۵
	S4 (.text + .rdata + .rsrc)	۰/۰۳۲۰	۰/۱۰۸۲۵	۰/۰۸۴۱۰	+۰/۰۰۵۲۱	۰/۰۸۲۹۷
	S5 (imgs-1024 + .text + .data)	۰/۰۲۸۶	۰/۰۲۳۴۱	۰/۰۳۶۵۰	+۰/۰۰۷۹	۰/۰۴۴۷۸
	S5 (imgs-1024 + .text + .rdata)	۰/۰۲۹۲	۰/۰۲۶۸۳	۰/۰۳۱۸۵	+۰/۰۰۲۷	۰/۰۴۰۱۹
	S5 (imgs-1024 + .text + .rdata + .data + .rsrc)	۰/۰۳۸۵	۰/۰۴۲۸۵	۰/۰۴۷۶۴	+۰/۰۰۹۱	۰/۰۵۷۴۵
	S5 (imgs-1024 + .text + .rsrc)	۰/۰۲۷۹	۰/۰۳۴۳۲	۰/۰۳۶۶۰	+۰/۰۰۸۷	۰/۰۳۷۸۶
	S5 (.text + .rdata + .data + .rsrc)	۰/۰۵۰۵	۰/۱۰۸۱۱	۰/۱۰۷۴۶	+۰/۰۰۵۷۰	۰/۱۵۵۹۹
	S5 (.text + .rdata + .rsrc)	۰/۰۴۴۶	۰/۱۱۳۵۷	۰/۱۱۹۷۸	+۰/۰۰۷۵۲	۰/۱۱۵۸۴



شکل ۳: مقایسه زیان لگاریتمی مقاله با بازتولید ما روی BIG 2015. لوزی سیاه نمره خصوصی گزارش شده مقاله است؛ نشانه‌های آبی اجرای ما با بودجه دوره مقاله و نشانه‌های نارنجی اجرای ۱۰ دوره‌ای هستند.

۵-۸ تحلیل

صحت آموزش بازتولید شد. همانند مقاله، همه پیکربندی‌ها به صحت نزدیک ۱۰۰٪ روی مجموعه آموزش رسیدند. این مشاهده تأیید می‌کند که ستون صحت آموزش در جدول ۵ مقاله واقعاً بی‌اطلاع است.

طرح‌های خام و Mask همراه تصویر خام با فاصله کم بازتولید شدند. میانگین اختلاف ما با مقاله برای شش پیکربندی S1-S3 برابر ۰/۰۰۵۰+ و برای پنج پیکربندی S5 همراه تصویر خام برابر ۰/۰۰۶۷+ است. بهترین نمره خصوصی ما ۰/۰۳۱۸۵ است در برابر ۰/۰۲۶۵ مقاله، یعنی حدود ۰/۰۰۵ بدتر. بهترین نمره عمومی ما ۰/۰۲۳۴۱ از تمام اعداد جدول ۵ کمتر است، ولی چون مقاله نمره خصوصی را ملاک گرفته، مقایسه منصفانه همان ستون خصوصی است.

ترتیب طرح‌های عرض روی ResNet50 دقیقاً بازتولید شد. در نتایج ما S3 با ۰/۰۳۴۴۶ بهتر از S1 با ۰/۰۳۶۰۱ و آن بهتر از S2 با ۰/۰۳۹۱۶ است؛ همان ترتیبی که مقاله گزارش می‌کند. روی VGG16 اما ترتیب بازتولید نشد: مقاله S1 را بهترین می‌داند در حالی که در اجرای ما S3 بهترین و S1 بدترین است. این ناسازگاری، ایراد «الف» در §۷ را تقویت می‌کند: تفاوت‌های کوچک میان این طرح‌ها پایدار نیستند.

بزرگ‌ترین واگرایی در S4 و S5 بدون تصویر خام رخ داد. میانگین اختلاف ما با مقاله برای شش پیکربندی S4 برابر ۰/۰۴۲۳+ و برای سه پیکربندی S5 بدون تصویر خام برابر ۰/۰۸۷۴+ است؛ یعنی یک مرتبه بزرگی بیش از واگرایی طرح‌های خام. این واگرایی نظام‌مند است و همه ۹ پیکربندی این دو خانواده را در بر می‌گیرد. پیامد آن مستقیماً به نتیجه‌گیری دوم مقاله می‌خورد: در اعداد مقاله S4 روی ResNet50 «مشابه» S1-S3 است، ولی در اعداد ما دو تا سه برابر بدتر. منشأ این شکاف (سیاست کانال‌های غایب، جزئیات منتشر نشده استخراج بخش‌ها، یا نوسان اجرا) را نمی‌توان تعیین کرد؛ ولی می‌توان گفت ادعای «قطعه‌بندی به‌تنهایی کافی است» با یک بازپیاپی‌سازی مستقل و وفادار به توصیف منتشر شده بازتولید نمی‌شود.

بودجه آموزش تعیین‌کننده نیست. در ۸ پیکربندی از ۲۰، اجرای ۱۰ دوره‌ای نمره خصوصی بهتری از اجرای با بودجه کامل داد. هیچ الگوی نظام‌مندی به سود بودجه بیشتر دیده نمی‌شود، که با اشیاع سریع صحت آموزش سازگار است.

۹ انتقال به دامنه نهفته: مجموعه‌داده ARM/Zephyr

۹-۱ انگیزه

پرسش دوم §۷، یعنی انتقال‌پذیری ایده به دامنه‌ای غیر از PE، هدف فاز چهارم بود و با موضوع درس نیز هم‌راستاست. استدلال معنایی مقاله درباره بخش‌ها ویژه ویندوز است: نقش کلیدی rsrsrc. از این فرض می‌آید که گونه‌های یک خانواده آیکون و منوی مشترک دارند، و در سفت‌افزار یک سامانه نهفته چنین بخشی وجود ندارد. پرسش این است که آیا قطعه‌بندی بخش محور در نبود این نشانه‌ها هم سودمند می‌ماند.

۹-۲ مجموعه‌داده

مجموعه‌داده از سفت‌افزارهای ساخته‌شده با سیستم عامل بی‌درنگ Zephyr [۸] برای هسته‌های ARM Cortex-M تشکیل شده است. ساختار تولید آن چنین است: ۵۳۱ برنامه نمونه Zephyr روی ۲۷۱ بورد هدف ساخته شده‌اند و ۱,۶۰۱ ساخت سالم به دست آمده است. برای هر ردهٔ بدافزار، یک «دستور تزریق» تعریف می‌شود که در آن دقیقاً یک فایل منبع از درخت Zephyr با یک گونه تغییر یافته جایگزین و پروژه از نو ساخته می‌شود. هر رده میان ۱۱ تا ۱۴ دستور تزریق متمایز دارد. جدول ۷ توزیع نهایی را نشان می‌دهد.

دو ویژگی این مجموعه‌داده باید صریح گفته شود، چون بر تفسیر همه نتایج بعدی اثر می‌گذارند. نخست، مجموعه‌داده ترکیبی و تولیدشده است و نه گردآوری شده از بدافزار واقعی؛ کلاس‌ها الگوی رفتاری را شبیه‌سازی می‌کنند و پسوند _like در نام آن‌ها همین را می‌رساند. دوم، تفاوت میان یک نمونه سالم و گونه بدافزاری هم‌تبار آن، جایگزینی یک فایل منبع از میان

جدول ۷: توزیع کلاس‌ها در مجموعه داده ARM/Zephyr


کلاس	نمونه	دستور تزریق	الگوی رفتاری هدف
benign	۱,۶۰۱	—	ساخت سالم بدون تغییر
backdoor_like	۵,۶۴۳	۱۴	مسیر فرمان پنهان در زیرسامانه پوسته یا شبکه
byovd_like	۴,۴۴۹	۱۱	سوءاستفاده از راه‌انداز مجاز برای دسترسی ممتاز
geofencing_like	۴,۶۴۷	۱۳	شرطی‌سازی رفتار بر پایه موقعیت یا شناسه شبکه
logic_bomb_like	۵,۱۸۵	۱۲	فعال‌سازی بار مخرب پس از شرط زمانی یا رویدادی
rootkit_like	۶,۰۴۶	۱۴	پنهان‌سازی از مسیرهای بازرسی سامانه
مجموع	۵۷۱,۲۷		

حدود صد واحد ترجمه پیوندخورده است. یعنی سیگنال کلاس یک اختلال کوچک و موضعی درون تصویری است که در بقیه نقاط یکسان می‌ماند، در حالی که تنوع میان نمونه‌ها (۵۳۱ برنامه در ۲۷۱ مورد) بسیار بزرگ است. این ساختار، مسئله را از انتساب خانواده در BIG 2015 به مراتب دشوارتر می‌کند و در §۱۱ به پیامدهای آن بازمی‌گردیم.

۳-۹ نداشت بخش‌ها از PE به ELF

معادل‌های مستقیم text، rodata و data. به سادگی نگاشت می‌شوند، اما rsrc. معادلی ندارد. در عوض، سفت‌افزار Zephyr چند بخش ویژه دارد که اطلاعات ساختاری ارزشمندی حمل می‌کنند و ما آن‌ها را به تقسیم‌بندی افزودیم: rom_start که جدول بردار وقفه Cortex-M را نگه می‌دارد، initlevel که ترتیب مقداردهی اولیه زیرسامانه‌ها را کدگذاری می‌کند، و چهار بخش device_area، device_api_area، device_states و sw_isr_table که در مجموع گراف راه‌اندازهای دستگاه و جدول روال‌های خدمت وقفه را توصیف می‌کنند. این انتخاب انگیزه امنیتی روشنی دارد: رده byovd_like بر سوءاستفاده از راه‌انداز مجاز استوار است، پس جدول‌های راه‌انداز محتمل‌ترین جایی هستند که اثر آن دیده شود.

برای هر نمونه، ۲۱ آرایه ذخیره می‌شود: سه بازنمایی خام S1، S2 و S3، و برای هر یک از نه بخش هدف، یک زیرتصویر S4 و یک زیرتصویر S5. شکل ۴ این بازنمایی‌ها را برای یک ساخت سالم و گونه backdoor_like هم‌تبار آن نشان می‌دهد.



شکل ۴: بازنمایی‌های S1 تا S5 برای یک ساخت سالم Zephyr (ردیف بالا) و گونه backdoor_like ساخته شده از همان ساخت (ردیف پایین). تفاوت دو ردیف با چشم عملاً تمیزناپذیر است، که دشواری مسئله را نشان می‌دهد. تئوری شدیدی S5 نیز در دو ستون آخر پیداست.

۴-۹ پروتکل ارزیابی

برخلاف BIG 2015، در اینجا سرور ارزیابی بیرونی با برچسب پنهان وجود ندارد. بنابراین یک تفکیک ۸۰ به ۲۰ لایه‌ای^{۱۴} با بذر ثابت ۴۲ تعریف کردیم و همه اعداد صحت، F1 کلان و ضریب همبستگی متیوز^{۱۵} [۹] که در این گزارش می‌آیند، روی همان ۲۰٪ نگه‌داشته شده محاسبه شده‌اند.

¹⁴Stratified

¹⁵Matthews Correlation Coefficient (MCC)

۵-۹ نتایج انتقال پایه

نخستین چرخه آزمایش، انتقال مستقیم روش با همان ابرپارامترهای جدول ۲ و ۲۰ دوره آموزش بود: ۱۹ پیکربندی با توصیف داده arm_zephyr در حالت شش کلاسه، بدون هیچ تغییری در رویه آموزش. جدول ۸ نتیجه را نشان می‌دهد. جدول ۸: انتقال پایه روش به ARM/Zephyr؛ ۱۹ پیکربندی، ۲۰ دوره، ابرپارامترهای مقاله. سه ستون نخست روی ۲۰٪ نگه‌داشته شده محاسبه شده‌اند.

مدل	پیکربندی	صحت	F1 کلان	MCC	صحت کل داده
ResNet50	S3	۶۵/۷۵٪	۰/۵۶۸۴	۰/۵۸۵۶	۷۳/۳۸٪
	S5: raw + rodata data	۶۵/۲۲٪	۰/۵۶۴۰	۰/۵۷۷۵	۷۲/۱۷٪
	S5: raw + text rodata data (4ch)	۶۲/۲۷٪	۰/۵۴۰۲	۰/۵۴۰۳	۷۱/۱۳٪
	S5: raw + text rodata data romstart (5ch)	۶۰/۱۸٪	۰/۵۱۹۱	۰/۵۱۱۶	۶۸/۶۰٪
	S2	۳۱/۸۶٪	۰/۲۷۰۹	۰/۱۵۹۵	۴۶/۸۹٪
	S5: raw + text rodata	۳۱/۶۸٪	۰/۲۳۰۷	۰/۱۶۲۵	۳۹/۶۳٪
	S5: raw + text data	۳۱/۵۱٪	۰/۲۶۹۴	۰/۱۵۶۲	۴۳/۸۴٪
	S1	۳۰/۹۳٪	۰/۲۳۶۸	۰/۱۴۶۲	۳۶/۶۴٪
	S4: text rodata data	۲۹/۰۳٪	۰/۲۳۷۲	۰/۱۳۲۹	۳۵/۴۷٪
	S5: text rodata data	۲۸/۵۸٪	۰/۱۹۷۲	۰/۱۲۳۱	۳۴/۵۳٪
	S4: text rodata data raw (4ch)	۲۴/۳۳٪	۰/۱۸۶۹	۰/۰۷۰۸	۲۷/۰۱٪
	S4: text rodata data romstart (4ch)	۲۱/۹۹٪	۰/۱۵۰۰	۰/۰۴۵۱	۲۵/۰۶٪
VGG16	S3	۳۸/۷۳٪	۰/۳۱۰۶	۰/۲۴۷۶	۶۰/۵۴٪
	S2	۳۸/۷۱٪	۰/۳۱۶۷	۰/۲۴۵۸	۶۵/۴۳٪
	S5: text rodata data	۳۷/۸۶٪	۰/۲۹۶۸	۰/۲۳۵۰	۵۰/۸۶٪
	S5: raw + text data	۳۷/۱۹٪	۰/۲۹۲۶	۰/۲۲۸۷	۵۷/۲۶٪
	S5: raw + text rodata	۳۵/۷۲٪	۰/۲۷۳۹	۰/۲۱۵۱	۵۳/۵۵٪
	S4: text rodata data	۳۲/۵۷٪	۰/۲۶۵۰	۰/۱۶۹۴	۵۲/۴۱٪
	S1	۳۱/۲۱٪	۰/۲۷۲۶	۰/۱۵۵۲	۵۱/۶۷٪

سه مشاهده از این جدول بیرون می‌آید. نخست، فاصله میان بهترین و بدترین پیکربندی بسیار بزرگ است (۶۵/۷۵٪) در برابر (۲۱/۹۹٪) و برخلاف BIG 2015 که همه پیکربندی‌ها در محدوده باریکی جمع بودند، در اینجا انتخاب بازنمایی تعیین‌کننده است. دوم، VGG16 در تمام پیکربندی‌ها به‌مراتب ضعیف‌تر از ResNet50 است؛ با توجه به ایراد «ب» در §۷ این مقایسه نیز مخدوش است، چون ابرپارامترهای دو مدل متفاوت مانده‌اند. سوم و مهم‌تر از همه، بررسی سنجه‌های درون‌کلاسی بهترین مدل نشان داد که بازخوانی کلاس benign دقیقاً صفر است: مدل حتی یک نمونه از ۳۲۰ نمونه سالم مجموعه نگه‌داشته‌شده را درست تشخیص نمی‌دهد و همه را به یکی از پنج ردهٔ بدافزار نسبت می‌دهد. این فروپاشی کامل کلاس اقلیت، انگیزه اصلی چرخه بعدی آزمایش‌ها شد.

۱۰ بهبودهای فاز چهارم و مطالعه حذفی

۱-۱۰ چرخه دوم: حذف کلاس سالم

نخستین واکنش به فروپاشی کلاس benign، حذف آن و بازتعریف مسئله به انتساب خانواده میان پنج ردهٔ بدافزار بود (۲۵،۹۷۰) نمونه؛ همان توصیف arm_zephyr با فهرست کلاس‌های پالوده). بهترین نتیجه این ۱۹ پیکربندی ۶۸/۱۴٪ برای ResNet50 روی S3 بود؛ یعنی حذف کلاس اقلیت صحت را تنها حدود دو واحد بالا می‌برد و مشکل اصلی، تمایز میان خانواده‌های بدافزار است نه حضور کلاس سالم. از سوی دیگر این صورت‌بندی از منظر امنیتی بی‌فایده است، چون همان تفکیکی را حذف می‌کند که بیشترین اهمیت را دارد؛ پس این مسیر را رها کردیم و به مسئله شش کلاسه بازگشتیم.

۲-۱۰ چرخه سوم: بهبود رویه آموزش

هر تغییر این چرخه، پاسخی به یکی از کاستی‌هایی است که در §۷ برای مقاله برشمردیم. جدول ۹ این نگاشت را به‌صورت صریح نشان می‌دهد و در ادامه، استدلال هر مورد می‌آید.

استدلال هر مورد کوتاه است. نمونه‌برداری وزن‌دار: کلاس benign تنها ۵/۸٪ داده را می‌سازد و در چرخه اول بازخوانی آن صفر شد؛ مقاله چنین وضعیتی را اصلاً نمی‌توانست ببیند، چون سنجه‌ای حساس به کلاس اقلیت گزارش نمی‌کرد. راه‌حل،

جدول ۹: نگاشت میان کاستی‌های شناسایی‌شده مقاله و تغییرهای فاز چهارم

کاستی مقاله	تغییر ما	نتیجه مشاهده‌شده
سنجه واحد و ناحساس به نامتوازی؛ نبود سنجه درون‌کلاسی	گزارش F1 کلان، MCC، ماتریس درهم‌ریختگی و سنجه‌های درون‌کلاسی برای هر اجرا	آشکار شدن فروپاشی کامل کلاس benign و کشف پدیده BYOVD
بی‌توجهی به نامتوازی داده در خود رویه آموزش	نمونه‌برداری وزن‌دار با وزن معکوس بسامد	بازخوانی benign از صفر به ۶۰/۳٪ و F1 کلان بهترین مدل از ۵۶۸۴/۰ به ۶۰۸۴/۰
زمان‌بند نرخ یادگیری تنها برای یکی از دو معماری و بدون توضیح	زمان‌بند کسینوسی یکسان برای هر دو معماری	رفع بخشی از ناهمگونی؛ نرخ یادگیری و اندازه دسته برای وفاداری به مقاله دست‌نخورده ماند
صحت آموزش اشباع و مدل بیش از حد مطمئن	هموارسازی برچسب با $\epsilon = ۰/۰۵$	بدون اثر مثبت بر داده دیده‌نشده؛ همراه با ۳۰ دوره به بیش‌برازش انجامید
معناشناسی بخش‌ها و ویژگی‌ها و غیرقابل انتقال	لایه پیکربندی مجموعه‌داده و تقسیم‌بندی بخش‌های ELF با جدول‌های ویژگی Zephyr	کانال‌های rodata – محور تنها کانال‌های بخشی رقابتی در این دامنه شدند
نبود هرگونه مجموعه اعتبارسنجی نگه‌داشته	تفکیک ۸۰ به ۲۰ لایه‌ای با بذر ثابت	معیار تعمیم به دست‌آمد؛ کاربرد نادرست اولیه آن در §۱۱ اصلاح شده است
مطالعه حذفی محدود به ۲۰ پیکربندی تک‌اجرا	۸۵ اجرا در چهار چرخه روی نمونه‌های موازی	پوشش گسترده‌تر فضای طراحی؛ مشکل تک‌بذر بودن همچنان باقی است

دیدن هر کلاس با احتمال متناسب با عکس بسامد آن است. زمان‌بند کسینوسی [۱۰] با $T_{\max} = ۳۰$ و $\eta_{\min} = ۱۰^{-۵}$ در مقاله تنها ResNet50 زمان‌بند دارد و VGG16 ندارد؛ ما سیاست یکسانی برای هر دو گذاشتیم تا دست‌کم این متغیر کنترل شود، و کسینوسی را از آن رو برگزیدیم که برخلاف کاهش نمایی ابرپارامتر آزاد اضافه‌ای وارد نمی‌کند. هموارسازی برچسب با $\epsilon = ۰/۰۵$ [۱۱]: مقاله خود صحت آموزش ۹۹/۹٪ تا ۱۰۰٪ گزارش می‌کند و چنین مدلی احتمال‌های نزدیک به یک می‌دهد که در زیان لگاریتمی پرهزینه است. کانال‌های rodata – محور: مقاله نقش کلیدی را به rsrsrc می‌دهد که در ELF وجود ندارد؛ نزدیک‌ترین معادل کارکردی آن، یعنی جدول رشته‌ها و ثابت‌ها، در rodata است و کد تزریق‌شده محتمل‌ترین اثرش را همان‌جا می‌گذارد.


بودجه آموزش نیز به ۳۰ دوره افزایش یافت و ۲۱ پیکربندی زیر توصیف arm_zephyr_optimized اجرا شد. جدول ۱۰ نتیجه را نشان می‌دهد. ستون آخر، صحت پس از ادغام دو کلاس benign و byovd_like است؛ دلیل تعریف این سنجه ثانویه در ادامه می‌آید.

جدول ۱۰: چرخه سوم روی ARM/Zephyr؛ ۲۱ پیکربندی، ۳۰ دوره، با نمونه‌برداری وزن‌دار، زمان‌بند کسینوسی و هموارسازی برچسب. همه اعداد روی ۲۰٪ نگه‌داشته‌شده.

مدل	پیکربندی	صحت	F1 کلان	MCC	صحت ادغامی
ResNet50	S3	۶۵/۲۶٪	۰/۶۰۸۴	۰/۵۸۹۱	۷۸/۴۴٪
	S5: raw + rodata data	۶۳/۰۵٪	۰/۵۸۶۶	۰/۵۶۱۳	۷۶/۱۲٪
	S5: raw + rodata initlevel	۶۲/۳۸٪	۰/۵۸۱۳	۰/۵۵۲۵	۷۵/۰۳٪
	S5: raw + rodata device	۶۱/۹۸٪	۰/۵۷۷۳	۰/۵۴۹۱	۷۴/۸۳٪
	S5: raw + rodata data initlevel (4ch)	۶۱/۸۰٪	۰/۵۷۴۹	۰/۵۴۳۳	۷۴/۸۷٪
	S5: raw + text rodata data romstart (5ch)	۵۷/۹۹٪	۰/۵۴۰۹	۰/۴۹۴۹	۷۰/۳۷٪
	S5: raw + text rodata data (4ch)	۵۵/۶۸٪	۰/۵۱۲۵	۰/۴۶۵۲	۶۹/۱۷٪
	S5: raw + rodata data s1 (4ch)	۵۳/۶۲٪	۰/۴۹۰۳	۰/۴۳۹۶	۶۶/۹۸٪
	S5: raw + s1 rodata data initlevel (5ch)	۳۰/۳۰٪	۰/۲۸۴۴	۰/۱۵۵۳	۴۲/۳۴٪
	S5: raw + s1 rodata	۲۷/۱۱٪	۰/۲۶۱۸	۰/۱۲۴۹	۳۷/۸۸٪
	S1	۲۶/۳۱٪	۰/۲۳۱۸	۰/۱۱۲۸	۳۶/۹۵٪
	S5: raw + text rodata	۲۶/۲۲٪	۰/۲۶۳۳	۰/۱۱۱۸	۳۷/۲۳٪
	S2	۲۵/۴۲٪	۰/۲۱۹۲	۰/۱۰۷۹	۳۶/۲۶٪
	S5: raw + text data	۲۵/۳۳٪	۰/۲۲۱۲	۰/۱۰۴۷	۳۵/۹۶٪
	S4: text rodata data raw (4ch)	۱۹/۵۸٪	۰/۱۳۸۰	۰/۰۳۹۲	۳۱/۰۱٪
VGG16	S3	۳۱/۲۲٪	۰/۲۷۴۲	۰/۱۶۳۸	۴۵/۷۵٪
	S5: raw + rodata data	۲۹/۱۷٪	۰/۲۶۳۷	۰/۱۴۰۳	۴۳/۷۵٪
	S2	۲۹/۰۷٪	۰/۲۵۸۹	۰/۱۳۷۵	۴۳/۶۳٪
	S1	۲۸/۴۹٪	۰/۲۵۵۸	۰/۱۳۱۸	۴۳/۰۳٪
	S5: raw + rodata initlevel	۲۸/۱۶٪	۰/۲۵۲۱	۰/۱۲۵۸	۴۲/۳۶٪
	S5: raw + s1 rodata	۲۷/۵۲٪	۰/۲۴۶۰	۰/۱۱۹۰	۴۲/۰۳٪

بازیابی کلاس سالم. مهم‌ترین دستاورد کیفی این چرخه همان چیزی است که انگیزه شروعش بود. در چرخه اول بهترین مدل هیچ‌یک از ۳۲۰ نمونه سالم مجموعه نگه‌داشته‌شده را تشخیص نمی‌داد و بازخوانی benign دقیقاً صفر بود؛ یعنی کلاس سالم عملاً از فضای خروجی مدل حذف شده بود. با نمونه‌برداری وزن دار، همین مدل ۱۹۳ نمونه از ۳۲۰ را درست تشخیص می‌دهد و بازخوانی به ۶۰/۳٪ می‌رسد و F1 کلان از ۰/۵۶۸۴ به ۰/۶۰۸۴ می‌رود. این از منظر کاربردی تعیین‌کننده است، چون مدلی که هیچ سفت‌افزار سالمی را سالم نمی‌داند در هر استقرار واقعی بی‌فایده است. نیمه دیگر تصویر آن است که دقت این کلاس ۱۹/۹٪ می‌ماند؛ ولی بخش عمده این خطا یک منشأ واحد و قابل تفسیر دارد.

پدیده BYOVD. ماتریس درهم‌ریختگی بهترین مدل (شکل ۵) یک الگوی روشن و قابل تفسیر نشان می‌دهد: از ۸۹۰ نمونه byovd_like در مجموعه نگه‌داشته‌شده، تنها ۲۲/۷٪ درست دسته‌بندی می‌شوند و ۶۹/۴٪ به کلاس benign نسبت داده می‌شوند. این دقیقاً همان چیزی است که از تعریف حمله انتظار می‌رود: در الگوی «راه‌انداز آسیب‌پذیر خود را بیاور»، مهاجم از یک راه‌انداز مجاز و بدون تغییر استفاده می‌کند و بنابراین تصویر سفت‌افزار نیز عملاً سالم است. چهار کلاس دیگر با F1 میان ۰/۷۴ و ۰/۷۹ از هم تفکیک می‌شوند. به همین دلیل، صحت پس از ادغام benign و byovd_like را به‌عنوان یک سنجه ثانویه گزارش می‌کنیم؛ ولی تأکید می‌کنیم که این سنجه نباید سنجه اصلی تلقی شود، چون دقیقاً پرهزینه‌ترین خطای ممکن در یک سامانه واقعی (گزارش بدافزار به‌عنوان سالم) را از شمارش خارج می‌کند.



شکل ۵: ماتریس درهم‌ریختگی بهترین مدل چرخه سوم (ResNet50 روی S3) روی ۵,۵۱۵ نمونه نگه‌داشته‌شده. سطر byovd_like الگوی غالب سردرگمی با کلاس benign را نشان می‌دهد.

۱۰-۳ چرخه چهارم: مدول ادغام هرمی و فیلترهای بافت

چرخه چهارم به دو کاستی دیگر می‌پردازد. مقاله در نتیجه‌گیری پیشنهاد می‌کند که با سازوکار توجه بتوان نواحی مهم تصویر را برجسته کرد ولی آن را پیاده نمی‌کند؛ ما یک سر ادغام هرمی^{۱۶} با الهام از PSPNet [۱۲] و چهار مقیاس 1×1 تا 6×6 را به‌عنوان نزدیک‌ترین گام عملی به آن ایده آزمودیم. همچنین مقاله بایت‌ها را تنها به‌عنوان شدت روشنایی خام می‌دهد و از توصیف‌گرهای بافت صریح استفاده نمی‌کند؛ ما دو کانال بافتی افزودیم که در زمان اجرا محاسبه می‌شوند: الگوی دودویی محلی^{۱۷} [۱۳] و پاسخ یک فیلتر گابور. در مجموع ۲۶ پیکربندی زیر توصیف arm_zephyr_optimized_ppm اجرا شد.


نتیجه یک شکست کامل بود. بهترین پیکربندی این چرخه تنها به ۲۴/۸۶٪ رسید و پیکربندی ResNet50 روی S3 که در چرخه سوم ۶۵/۲۶٪ داشت، با افزودن PPM به ۱۴/۲۹٪ سقوط کرد. میانگین افت روی ۱۹ پیکربندی مشترک میان دو چرخه برابر ۲۰/۷ واحد است. شکل ۶ منحنی‌های آموزش را کنار هم می‌گذارد و نکته تعیین‌کننده را آشکار می‌کند: با PPM، صحت مجموعه آموزش نیز از ۲۵٪ فراتر نمی‌رود. یعنی این یک شکست در تعمیم نیست، بلکه شکست در برازش است.

ریشه‌یابی. بازخوانی کد سه علت مشخص را نشان می‌دهد و هر سه به پیاده‌سازی ما برمی‌گردند، نه به ایده PPM:

- هر شاخه هرم پس از ادغام به اندازه $s \times s$ و یک پیچش 1×1 ، دوباره یک AdaptiveAvgPool2d(1) می‌خورد؛ یعنی همان اطلاعات مکانی چندمقیاسی که کل هدف PPM است بی‌درنگ میانگین‌گیری و دور ریخته می‌شود، در حالی

¹⁶Pyramid Pooling Module (PPM)

¹⁷Local Binary Pattern (LBP)



شکل ۶: منحنی‌های آموزش ResNet50 روی S3، با و بدون سر ادغام هرمی. در نمودار راست، صحت آموزش نیز در سطح تصادفی می‌ماند؛ نشانه شکست بهینه‌سازی و نه بیش‌برازش.

که در PSPNet اصلی نقشه‌های ادغام‌شده باز نمونه‌برداری و به‌صورت مکانی الحاق می‌شوند. آنچه ساختیم یک هرم نیست، بلکه چهار توصیفگر سراسری تقریباً زائد است.

۲. این سر برای ResNet50 حدود ۴,۱۹۴,۳۰۴ پارامتر پیچشی با مقداردهی تصادفی می‌افزاید که با نرخ یادگیری ۰/۰۱ و کاهش وزن ۰/۰۰۶ جدول ۲ آموزش می‌بیند؛ گرادین‌های اولیه آن، ویژگی‌های از پیش‌آمोخته ستون فقرات را در همان دوره‌های نخست تخریب می‌کنند.

۳. در VGG16 جایگزینی avgpool با این سر، ورودی classifier[0] را از ۲۵,۰۸۸ به ۱,۰۲۴ می‌کاهد و وزن‌های از پیش‌آمोخته آن لایه نیز دور ریخته می‌شوند.

پس نتیجه‌گیری درست آن است که پیاده‌سازی ما از PPM نادرست بوده، نه اینکه ادغام هرمی برای این مسئله نامناسب است؛ توضیحی از جنس «شکستن ناوردایی انتقالی» هم سازگار نیست، چون چنین استدلالی درباره تعمیم است و اینجا مدل حتی داده آموزش را برازش نمی‌کند. کانال‌های LBP و گابور نیز زیر سایه همین شکست اجرا شدند و درباره سودمندی مستقل آن‌ها نمی‌توان نتیجه‌ای گرفت؛ ضمن اینکه فیلتر گابور پیاده‌شده تنها یک جهت و یک بسامد دارد، در حالی که کاربرد متعارف آن یک بانک چندجهته است.

۱۰-۴ مقایسه ماتریس‌های درهم‌ریختگی چهار چرخه


شکل ۷ ماتریس درهم‌ریختگی ResNet50 روی S3 را برای هر چهار چرخه، همگی روی همان ۲۰٪ نگه‌داشته‌شده و بهنجار شده بر سطر، کنار هم می‌گذارد. چهار پدیده‌ای که در متن توصیف شد، اینجا به‌صورت بصری قابل ردیابی‌اند.

در چرخه اول، کل ستون benign صفر است: مدل هرگز برچسب سالم را پیش‌بینی نمی‌کند و نمونه‌های سالم میان backdoor و byovd پخش می‌شوند. نکته ظریف این است که بازخوانی byovd در همین چرخه ۶۶/۱٪ است، یعنی بالاتر از چرخه سوم؛ ولی این رقم دست‌آورد نیست، چون byovd صرفاً نقش سطل نمونه‌های سالم‌مانند را بازی می‌کند. چرخه دوم با حذف کلاس سالم، ماتریسی متعادل با قطر ۶۳٪ تا ۷۹٪ می‌سازد، ولی به بهای حذف تفکیکی که در عمل مهم‌ترین است. در چرخه سوم قطر شش‌کلاسه بازمی‌گردد و ستون benign فعال می‌شود، و همان‌طور که انتظار می‌رفت بار خطا روی سطر byovd متمرکز می‌ماند. در چرخه چهارم، PPM ماتریس را به دو ستون benign و backdoor فرو می‌کاهد و ستون‌های logic_bomb و rootkit عملاً خالی می‌شوند؛ رفتاری که با یک طبقه‌بند آموزش‌ندیده سازگار است، نه با مدلی که آموخته و بد تعمیم داده است.

۱۰-۵ هزینه استنتاج

از آنجا که مقصد نهایی چنین طبقه‌بندی یک سامانه نهفته یا دروازه اینترنت اشیاء است، هزینه استنتاج هم باید کنار صحت گزارش شود. جدول ۱۱ میانگین زمان استنتاج بر نمونه را بر حسب معماری و تعداد کانال نشان می‌دهد؛ همه اعداد روی همان نمونه‌های پردازنده گرافیکی کگل و با دقت مختلط اندازه‌گیری شده‌اند.

سه نکته از این جدول بیرون می‌آید. ResNet50 در تعداد کانال برابر حدود ۱/۷ برابر سریع‌تر از VGG16 است و هم‌زمان



شکل ۷: ماتریس درهم‌ریختگی ResNet50 روی S3 در چهار چرخه آزمایش، روی مجموعه نگه‌داشته‌شده و بهنجار شده بر سطر (درصد بازخوانی هر کلاس).

جدول ۱۱: میانگین هزینه استنتاج بر نمونه (چرخه سوم، مگر جایی که خلاف آن ذکر شده)

مدل	کانال	زمان (میلی ثانیه)	گذردهی (نمونه بر ثانیه)	بهترین صحت نگه‌داشته
ResNet50	۳	۱/۷۹	۵۵۹	۶۵/۲۶٪
ResNet50	۴	۱/۹۸	۵۰۵	۶۱/۸۰٪
ResNet50	۵	۲/۳۲	۴۳۱	۵۷/۹۹٪
VGG16	۳	۳/۱۲	۳۲۱	۳۱/۲۲٪
PPM با ResNet50	۳	۲/۳۳	۴۲۹	۱۴/۲۹٪

صحت به مراتب بالاتری می‌دهد، پس در این دامنه هیچ دلیلی برای انتخاب VGG16 نمی‌ماند. هر کانال بخش اضافه حدود ۰/۱ تا ۰/۲ میلی ثانیه به تأخیر می‌افزاید و هم‌زمان صحت را پایین می‌آورد؛ یعنی کانال‌های بیشتر در هر دو محور بازنده‌اند. و سر PPM حدود ۳۰٪ تأخیر اضافه می‌کند در حالی که صحت را نابود می‌سازد. باید تأکید کرد که این اعداد روی پردازنده گرافیکی مرکز داده گرفته شده‌اند و برای استقرار روی خود دستگاه نهفته، اندازه‌گیری جداگانه روی سخت‌افزار هدف لازم است.

۱۰-۶ هزینه محاسباتی و نقش موازی سازی

مجموع زمان آموزش چهار چرخه حدود ۸۷ ساعت پردازنده گرافیکی است (به ترتیب ۱۵/۴، ۱۴/۳، ۲۵/۲ و ۳۱/۶ ساعت) و همه اجراها روی نمونه های رایگان کگل انجام شدند. این عدد به تنهایی گمراه کننده است، چون سقف زمان هر جلسه کگل محدود است و اجرای سریالی چنین حجمی عملاً ناممکن بود. راهکار ما تقسیم متوازن پیکربندی های هر چرخه میان سه تا چهار نمونه موازی بود؛ با این تقسیم، زمان دیواری هر چرخه به طور میانگین به حدود ۳ ساعت برای دو چرخه نخست، ۶ ساعت برای چرخه سوم و ۱۰ ساعت برای چرخه چهارم رسید. بدون این موازی سازی، آزمودن ۸۵ پیکربندی در بازه این فاز ممکن نبود و ناچار می شدیم مطالعه حذفی را به چند پیکربندی محدود کنیم؛ یعنی دقیقاً همان کمبودی که در §۷ به مقاله گرفتیم. ضمناً چرخه چهارم با میانگین ۱۰ ساعت به سقف زمان جلسه نزدیک شده بود و فضای بیشتری برای گسترش نمی گذاشت.

۱۱ بازارزیابی انتقادی نتایج خودمان

اگر قرار است نقد §۷ جدی گرفته شود، باید همان سخت گیری را درباره کار خودمان هم به کار بست.

۱-۱۱ نقصی در پروتکل ارزیابی و اصلاح آن

تابع آموزش، مجموعه فایل ها را با تفکیک ۸۰ به ۲۰ لایه ای می شکند، ولی سنجه های اصلی (صحت، F1 کلان، MCC، گزارش درون کلاسی و ماتریس درهم ریختگی) روی کل ۲۷,۵۷۱ نمونه محاسبه می شدند، چون بازگذار ارزیابی روی همه فایل ها ساخته شده بود. سنجه حاصل میانگین وزن داری میان حافظه مدل و تعمیم آن است و دقیقاً بازسازی پذیر است؛ برای بهترین مدل چرخه سوم:

$$(2) \quad 0.8 \times 83.52 + 0.2 \times 65.26 = 79.87$$


و برای VGG16 روی S3 به صورت $0.8 \times 86.19 + 0.2 \times 31.22 = 75.19$ یعنی عدد ۷۵/۱۹٪ برای VGG16 تقریباً به تمامی از حفظ کردن داده آموزش می آید و صحت واقعی آن روی داده دیده نشده ۳۱/۲۲٪ است.

برای اصلاح، تفکیک اصلی را با همان بذر و ترتیب فایل ها بازسازی و همه سنجه ها را برای هر ۸۵ اجرا از نو محاسبه کردیم؛ درستی بازسازی با تطبیق تا چهار رقم اعشار با مقادیر اعتبارسنجی ثبت شده تأیید شد. تمام اعداد جدول های ۸ و ۱۰ خروجی همین محاسبه اند و شکل ۸ اندازه شکاف را نشان می دهد.

۱۱-۲ آیا بهبودهای فاز چهارم واقعاً بهبود بودند؟

دوازده پیکربندی میان چرخه اول و چرخه سوم مشترک اند و مقایسه زوجی آن ها پاسخ روشنی می دهد: صحت کل داده به طور میانگین ۵/۰۱ واحد بالا رفته، ولی صحت روی داده نگه داشته شده به طور میانگین ۴/۹۰ واحد پایین آمده و این کاهش در هر ۱۲ پیکربندی بدون استثنا رخ داده است. یعنی افزایش بودجه آموزش از ۲۰ به ۳۰ دوره عمدتاً ظرفیت حفظ داده آموزش را افزوده است.

با این حال نتیجه گیری «بهبودها بی فایده بودند» نادرست است: برای دو پیکربندی برتر F1 کلان بهبود یافته (ResNet50 روی S3 از ۵۶۸۴/۰ به ۶۰۸۴/۰) و ریشه آن در بازخوانی کلاس benign است که از صفر به ۶۰/۳٪ رسیده، هرچند به بهای افت دقت آن کلاس به ۱۹/۹٪. ارزیابی منصفانه این است که نمونه برداری وزن دار فروپاشی کلاس اقلیت را درمان کرده ولی صحت کلی را بالا نبرده است؛ بزرگ ترین بازنده VGG16 است که صحت داده دیده نشده اش از ۳۸/۷۳٪ به ۳۱/۲۲٪ افت کرده است.



شکل ۸: شکاف میان صحت کل داده و صحت روی ۲۰٪ نگه‌داشته‌شده، برای ۲۱ پیکربندی چرخه سوم. شکاف در پیکربندی‌های VG16 از ۴۰ واحد فراتر می‌رود.

۱۱-۳ نشت گروهی در تفکیک تصادفی

حتی عدد اصلاح‌شده ۶۵/۲۶٪ نیز باید با احتیاط خوانده شود. چون هر ساخت پایه هم به‌صورت نمونه سالم و هم به‌صورت گونه بدافزاری هر پنج رده حاضر است (۹)، با تفکیک تصادفی در سطح نمونه ۱۰۰٪ ساخت‌های پایه مجموعه نگه‌داشته‌شده در آموزش نیز دیده شده‌اند و ۹۹/۹۸٪ نمونه‌های نگه‌داشته‌شده از دستور تزریقی می‌آیند که مدل نمونه‌های دیگری از آن را دیده است. با ۱۱ تا ۱۴ دستور تزریق در هر رده، آنچه اندازه می‌گیریم «بازشناسی دستور تزریق آشنا روی ساخت آشنا» است، نه تعمیم به سفت‌افزار یا گونه بدافزار جدید. این همان دامی است که در ادبیات یادگیری ماشین امنیتی بارها هشدار داده شده [۱۴، ۱۵]؛ ارزیابی درست نیازمند تفکیک گروهی بر پایه شناسه ساخت پایه و شناسه دستور تزریق است که در بودجه محاسباتی این فاز ننگجید.

۱۱-۴ آیا ایده مرکزی مقاله در این دامنه کارگر بوده است؟

پرسش اصلی فاز چهارم همین بود. جدول ۱۲ بهترین نتیجه هر خانواده طرح را در چهار آزمایش کنار هم می‌گذارد. جدول ۱۲: بهترین نتیجه هر خانواده طرح روی ResNet50. ستون نخست زیان لگاریتمی است (کمتر بهتر) و سه ستون دیگر صحت روی داده نگه‌داشته‌شده (بیشتر بهتر). ستون ۵- کلاسه با دو ستون دیگر ARM مستقیماً مقایسه‌پذیر نیست.

خانواده طرح	BIG 2015	ARM پایه	ARM ۵-کلاسه	ARM چرخه سوم
S3-S1 خام (بهترین: S3)	۰/۰۳۴۴۶	۶۵/۷۵٪	۶۸/۱۴٪	۶۵/۲۶٪
S4 خالص (Split)	۰/۰۸۲۴۴	۲۹/۰۳٪	۲۶/۳۸٪	—
S5 خالص (Mask)	۰/۱۰۷۴۶	۲۸/۵۸٪	۲۷/۲۰٪	—
S5 + خام، ۳ کاناله	۰/۰۳۱۸۵	۶۵/۲۲٪	۶۸/۰۲٪	۶۳/۰۵٪
S5 + خام، ۴ کاناله	—	۶۲/۲۷٪	۵۹/۹۷٪	۶۱/۸۰٪
S5 + خام، ۵ کاناله	۰/۰۴۷۶۴	۶۰/۱۸٪	۵۸/۵۵٪	۵۷/۹۹٪

معیار درست و پاسخ. معیار، «بهتر بودن از S3» نیست؛ در جدول ۵ خود مقاله هم S3 بهترین ردیف است و هیچ پیکربندی قطعه‌بندی از آن جلو نمی‌زند. ادعای مقاله رسیدن به نتیجه‌ای نزدیک در ازای استقلال از چیدمان فضایی است؛ یعنی یک معامله. پرسش درست این است که آیا این معامله در دامنه نهفته هم به‌صرفه می‌ماند. پاسخ ما منفی است. روی BIG 2015 و با اعداد خود مقاله، بهترین S4 با ۰/۰۳۲۰ حدود ۲۱٪ بدتر از S3 است؛ یک جریمه محسوس ولی قابل دفاع در برابر آنچه به دست می‌آید. در بازتولید ما همین فاصله به ۰/۰۸۲۴۴ در برابر ۰/۰۳۴۴۶، یعنی نزدیک به دو و نیم برابر، گشوده می‌شود و

ادعای «نزدیک بودن» دیگر برقرار نیست. روی ARM/Zephyr معامله به کلی فرو می‌پاشد: بهترین S4 به ۲۹/۰۳٪ و بهترین S5 بدون تصویر خام به ۲۸/۵۸٪ می‌رسند، در حالی که S3 به‌تنهایی ۶۵/۷۵٪ می‌دهد. جریمه بیش از نصف صحت است و هیچ مقدار استقلال فضایی چنین هزینه‌ای را توجیه نمی‌کند.

نکته تعیین‌کننده درباره S5 همراه تصویر خام. تنها خانواده‌ای که روی ARM به S3 نزدیک می‌ماند (۶۵/۲۲٪) در برابر ۶۵/۷۵٪ همان است که تصویر خام عرض ثابت را به‌عنوان یکی از کانال‌ها نگه می‌دارد؛ اما دقیقاً همین کانال وابستگی به چیدمان فضایی کل فایل را باز می‌گرداند. یعنی تنها شکلی از قطعه‌بندی که در این دامنه کارایی قابل قبول دارد، هدف اصلی قطعه‌بندی را برآورده نمی‌کند. افزون بر این، افزودن هر کانال بخش اضافه صحت را یکنواخت کاهش می‌دهد: ۶۵/۲۶٪، ۶۳/۰۵٪، ۶۱/۸۰٪ و ۵۷/۹۹٪ به‌ترتیب با صفر تا چهار کانال بخش. باید تصریح کرد که نیمه سود این معامله را نه مقاله و نه ما اندازه نگرفته‌ایم؛ آنچه می‌توان گفت این است که هزینه آن در دامنه نهفته بسیار سنگین‌تر از دامنه PE است.

چرا هزینه در این دامنه این‌قدر بیشتر است؟ چهار تفاوت ساختاری این واگرایی را توضیح می‌دهند. **ماهیت سیگنال کلاس:** در 2015 BIG کلاس‌ها برنامه‌هایی کاملاً متفاوت‌اند و جدا کردن بخش‌ها نوسان بی‌ربط چیدمان را حذف می‌کند؛ در مجموعه داده ما هر شش کلاس روی همان ساخت‌های پایه بنا شده‌اند و تنوع درون‌کلاسی (۵۳۱ برنامه در ۲۷۱ بورد) به‌مراتب بزرگ‌تر از تفاوت بین‌کلاسی است، پس قطعه‌بندی همان تنوع بی‌ربط را جدا می‌کند نه سیگنال را. **غیاب بخش نشانه‌دار:** استدلال مقاله درباره rsrc. بر اشتراک منابع میان گونه‌های یک خانواده استوار است و در Zephyr چنین بخشی نیست؛ جایگزین‌های ساختاری ما تنها چند صد بایت‌اند و کشیدن آن‌ها به بوم 224×224 بافتی می‌سازد که بیشتر محصول درونیابی است تا محتوای فایل. **هزینه پیش‌آموزش:** برای بیش از سه کانال لایه ورودی از نو مقداردهی می‌شود؛ روی BIG 2015 این هزینه قابل تحمل بود ولی روی ARM تعیین‌کننده می‌شود و همان کاهش یکنواخت جدول ۱۲ را می‌سازد. **اشباع مسئله:** روی BIG 2015 همه ۲۰ پیکربندی به زیان کمتر از ۰/۱۱ رسیدند و تفاوت بازنمایی‌ها در حاشیه‌ای باریک و غیرقابل تفکیک از نوسان ظاهر می‌شود، در حالی که روی ARM همان انتخاب فاصله‌های ۳۰ تا ۴۰ واحدی می‌سازد.

آنچه کارگر بود. سهم دوم مقاله، یعنی هم‌ترازی عرض، در دامنه جدید به‌مراتب قوی‌تر از دامنه اصلی تأیید شد: روی BIG 2015 فاصله S1 و S3 در حد ۰/۰۰۲ زیان لگاریتمی است، ولی روی ARM همین فاصله ۶۵/۷۵٪ در برابر ۳۰/۹۳٪ می‌شود. دلیلش ساختاری است: اندازه فایل‌های این مجموعه داده از ۲۳۹ کیلوبایت تا ۱۰۵ مگابایت تغییر می‌کند و جدول Nataraj برای این بازه سه عرض متفاوت (۵۱۲، ۷۶۸ و ۱۰۲۴) تخصیص می‌دهد و مخلوط شدن آن‌ها مقایسه‌پذیری بافت میان نمونه‌ها را از میان می‌برد. مشاهده مقاله درباره سهم نابرابر بخش‌ها نیز تأیید شد، هرچند با فهرست متفاوتی از بخش‌ها: پیکربندی‌هایی که کانال دوشان rodata است به ۶۲٪ تا ۶۳٪ می‌رسند و پیکربندی‌های مبتنی بر text در سطح ۲۵٪ تا ۲۶٪ می‌مانند. درباره این تفاوت اخیر باید محتاط بود: اجراهای مبتنی بر text حتی مجموعه آموزش را هم به‌خوبی برازش نکرده‌اند (صحت آموزش ۵۷٪ در برابر ۸۱٪) و با یک بذر برای هر پیکربندی نمی‌توان اثر بازنمایی را از شکست بهینه‌سازی جدا کرد؛ عیناً همان ایرادی که در §۷ به مقاله گرفتیم و اکنون به کار خودمان نیز وارد است.

۱۱-۵ سایر محدودیت‌های کار ما

- **بذر تصادفی واحد.** هر ۸۵ اجرا با بذر ۴۲ انجام شده؛ هیچ بازه اطمینانی در دست نیست و هیچ ادعای معناداری آماری قابل دفاع نیست.
- **ماهیت ترکیبی مجموعه داده و نبود آزمون مقاومت.** نتایج درباره سفت‌افزارهای تولیدشده با الگوهای تزریق کنترل‌شده‌اند و نه بدافزار واقعی؛ افزون بر این، ما نیز همان آزمایشی را که نبودش را به مقاله ایراد گرفتیم انجام ندادیم و هیچ ارزیابی‌ای زیر بازآرایی بخش‌ها صورت نگرفته است.
- **مقایسه معماری‌ها همچنان مخدوش است.** ابرپارامترهای دو معماری را عمداً از مقاله نگه داشتیم تا بازتولید وفادار بماند؛ پس قضاوت ما درباره برتری ResNet50 همان اشکال §۷ را دارد.

۱۲ جمع‌بندی، محدودیت‌ها و کارهای آینده

۱-۱۲ جمع‌بندی درباره مقاله

مقاله Nie ایده‌ای ساده و مفهومی تمیز پیشنهاد می‌کند: بخش‌های فایل اجرایی به کانال‌های جداگانه نگاشته شوند تا مرزبندی بخش‌ها به‌جای استنتاج از بافت، در ساختار ورودی کدگذاری شود. سنجه ارزیابی بیرونی، ثابت نگه داشتن عرض پایه در طرح‌های قطعه‌بندی و بخش محدودیت‌های صادقانه، امتیازهای واقعی این کاراند.

در مقابل، شواهد بار ادعاها را تحمل نمی‌کنند: رتبه‌بندی ۲۰ پیکربندی بدون تکرار یا بازه اطمینان گزارش شده در حالی که پنج ردیف برتر در بازه‌ای به پهنای ده درصد نسبی جای می‌گیرند؛ دو معماری با چهار ابرپارامتر متفاوت مقایسه شده‌اند؛ و مهم‌تر از همه، ادعای محوری مقاومت در برابر مبهم‌سازی که انگیزه اصلی کل روش است در هیچ آزمایشی سنجیده نمی‌شود.

۲-۱۲ جمع‌بندی درباره کار ما

بازتولید ۲۰ پیکربندی روی BIG 2015 نشان داد طرح‌های خام و Mask همراه تصویر خام با فاصله میانگین کمتر از ۰/۰۰۷ زیان لگاریتمی بازتولید می‌شوند، ولی S4 و S5 بدون تصویر خام با فاصله‌ای یک مرتبه بزرگی بیشتر واگرا می‌شوند. ترتیب طرح‌های عرض روی ResNet50 دقیقاً بازتولید شد ولی روی VGG16 برعکس درآمد، که شکستگی این رتبه‌بندی‌ها را تأیید می‌کند.

انتقال روش به ۲۷,۵۷۱ سفت‌افزار ARM/Zephyr پاسخ روشی به پرسش انتقال‌پذیری داد. مقاله هرگز ادعا نکرده که قطعه‌بندی بهترین صحت را می‌دهد (در جدول ۵ خود مقاله هم S3 بهترین است)؛ ادعا این است که قطعه‌بندی به صحتی نزدیک می‌رسد و در عوض استقلال از چیدمان فضایی را به دست می‌آورد. در دامنه نهفته هزینه این معامله بسیار سنگین‌تر می‌شود: بهترین S4 به ۲۹/۰۳٪ و بهترین S5 بدون تصویر خام به ۲۸/۵۸٪ می‌رسند، در حالی که یک رستر ساده با عرض ثابت ۶۵/۷۵٪ می‌دهد. تنها خانواده‌ای که نزدیک می‌ماند همان است که تصویر خام را نگه می‌دارد و در نتیجه همان وابستگی فضایی را باز می‌گرداند که قرار بود حذف شود. در مقابل، سهم دوم مقاله یعنی اهمیت هم‌ترازی عرض، در این دامنه به‌مراتب قوی‌تر از دامنه اصلی تأیید شد: فاصله عرض ثابت و عرض تطبیقی از ۰/۰۰۲ زیان لگاریتمی روی BIG 2015 به ۳۵ واحد صحت روی ARM می‌رسد. مشاهده مقاله درباره سهم نابرابر بخش‌ها نیز تأیید شد، هرچند با فهرست کاملاً متفاوتی از بخش‌های مؤثر.

بازبینی انتقادی کار خودمان دو یافته داشت. نخست، پروتکل ارزیابی اولیه سنجه‌ها را روی کل مجموعه داده محاسبه می‌کرد و سرخط ۷۹/۸۷٪ در واقع ترکیب $۰/۲ \times ۶۵/۲۶ + ۸۳/۵۲ \times ۰/۸$ بود؛ پس از اصلاح، هیچ‌یک از دوازده پیکربندی مشترک با چرخه پایه از نظر صحت کلی بهبود نشان نمی‌دهد. دستاورد واقعی چرخه سوم جای دیگری است: کلاس benign که در چرخه پایه با بازخوانی صفر فرو ریخته بود، با نمونه‌برداری وزن‌دار به بازخوانی ۶۰/۳٪ بازگشت و F1 کلان بهترین مدل از ۰/۵۶۸۴ به ۰/۶۰۸۴ رسید؛ برای یک سامانه تشخیص این تفاوت میان مدل بی‌استفاده و مدل قابل بحث است. دوم، تفکیک تصادفی در سطح نمونه نشت گروهی دارد و حتی عدد اصلاح‌شده نیز سقفی خوش‌بینانه است.

۳-۱۲ کارهای آینده

سه اولویت، به ترتیب اهمیت:

۱. ارزیابی با تفکیک گروهی. بازآموزی پیکربندی‌های برتر با گروه‌بندی بر پایه شناسه ساخت پایه و سپس شناسه دستور تزییق؛ تنها راه سنجش تعمیم واقعی به سفت‌افزار و گونه دیده‌نشده.
۲. آزمون مقاومت در برابر مبهم‌سازی. ارزیابی مدل‌های آموزش دیده روی نمونه‌هایی با بخش‌های بازآراییده یا داده زائد تزییق‌شده و مقایسه افت S3 با S4؛ تنها راه سنجش مستقیم ادعای محوری مقاله.
۳. اصلاح سر ادغام هرمی. پیاده‌سازی درست PSPNet با الحاق مکانی نقشه‌های ادغام‌شده و نرخ یادگیری جداگانه برای سر تازه؛ تنها پس از آن می‌توان درباره سودمندی ادغام هرمی داوری کرد.

در کنار این سه، تکرار اجراها با چند بذر کمترین کار لازم برای قابل دفاع کردن هر رتبه‌بندی است.

مراجع

- [1] R. Ronen, M. Radu, C. Feuerstein, E. Yom-Tov, and M. Ahmadi, "Microsoft malware classification challenge," *arXiv preprint arXiv:1802.10135*, 2018.
- [2] L. Nataraj, S. Karthikeyan, G. Jacob, and B. S. Manjunath, "Malware images: Visualization and automatic classification," in *Proc. 8th Int. Symp. on Visualization for Cyber Security (VizSec)*, 2011.
- [3] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Int. Conf. on Learning Representations (ICLR)*, 2015.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [5] D. Vasan, M. Alazab, S. Wassan, H. Naeem, B. Safaei, and Q. Zheng, "IMCFN: Image-based malware classification using fine-tuned convolutional neural network architecture," *Computer Networks*, vol.171, p.107138, 2020.
- [6] M. Xiao, C. Guo, G. Shen, Y. Cui, and C. Jiang, "Image-based malware classification using section distribution information," *Computers & Security*, vol.110, p.102420, 2021.
- [7] R. Chaganti, V. Ravi, and T. D. Pham, "Image-based malware representation approach with EfficientNet convolutional neural networks for effective malware classification," in *Journal of Information Security and Applications*, 2022.
- [8] Zephyr Project, "Zephyr project: An open source RTOS for connected, resource-constrained devices," <https://www.zephyrproject.org>, 2024.
- [9] D. Chicco and G. Jurman, "The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation," *BMC Genomics*, vol.21, no.6, 2020.
- [10] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," in *Int. Conf. on Learning Representations (ICLR)*, 2017.
- [11] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [12] H. Zhao, J. Shi, X. Qi, X. Wang, and J. Jia, "Pyramid scene parsing network," in *IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [13] T. Ojala, M. Pietikäinen, and T. Mäenpää, "Multiresolution gray-scale and rotation invariant texture classification with local binary patterns," *IEEE Trans. on Pattern Analysis and Machine Intelligence*, vol.24, no.7, pp.971–987, 2002.
- [14] D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro, and K. Rieck, "Dos and don'ts of machine learning in computer security," in *31st USENIX Security Symposium*, 2022.
- [15] F. Pendlebury, F. Pierazzi, R. Jordaney, J. Kinder, and L. Cavallaro, "TESSERACT: Eliminating experimental bias in malware classification across space and time," in *28th USENIX Security Symposium*, 2019.